ANZIZA Ahamada Madi
ARDACHAM Mahamat Teguene

Étudiants en Licence 3 MIASHS
2024-2025

Aix Marseille Université

ATELIER MATHS

TRAVAUX PRATIQUES : RÉPARTITION DES REVENUS

CAS D'ITALIE : 2020 & 1940

Responsables :
PIERRE ARNOUX
DOMINIQUE AMI

Sommaire

INTRODUCTION

LE TRAVAIL DEMANDE POUR LE TP

CONCLUSION

BIBLIOGRAPHIE

INTRODUCTION

La répartition des revenus en économie est l'un des sujets les plus centraux lorsqu'on parle d'analyse des inégalités au sein d'un État. La loi de Pareto, abordée par l'économiste Vilfredo en fin du XIXe siècle met en évidence une régularité remarquable, une partie supérieure de la distribution des revenus qui se concentre sur le 1% des plus riches.
Le principe de Pareto est une méthode qui permet de diviser un ensemble en deux groupes : les problèmes vitaux et les problèmes plus secondaires dans tous les cas, l'application du principe de Pareto permet d'identifier les propriétés des problèmes stratégiques et de les séparer des autres.
Durant notre étude, nous allons vérifier dans quelle mesure la loi de Pareto s'applique à la répartition des revenus d'Italie qu'on a trouvé via le site WID.world.

Ensuite nous allons :

- Extraire et traiter les données relatives aux revenus individuels dans le haut de la distribution.
- Représenter graphiquement ces données en échelle logarithmique pour identifier un éventuel alignement linéaire (caractéristique d'une loi de Pareto).
- Calculer les paramètres α et β associés à cette distribution
- Évaluer la pertinence du modèle de Pareto dans le cas étudié.

Cette analyse nous permettra de mieux comprendre la structure des inégalités de revenus dans les tranches les plus élevées de la population, ainsi que l'évolution éventuelle de ces inégalités dans le temps.

LE TRAVAIL DEMANDE POUR LE TP

1. Chargement des donnés

Il faut aller sur le site WID.WORLD, et télécharger leurs données.

Importation de notre base de données

Pour commencer, nous avons importé les données depuis **WID.WORLD**, et avons choisi l'Italie afin d'analyser la répartition des revenus. On a ensuite utilisé le logiciel R pour charger et explorer ces données. Pour cela, on a d'abord importé les bibliothèques nécessaires, notamment ggplot2 pour la visualisation graphique et dplyr pour la manipulation de données. Les données ont été importées à l'aide de la fonction read.csv2(), en veillant à utiliser le bon séparateur (;) et à conserver les colonnes textuelles en tant que chaînes de caractères.

Code R

```{r}
# Charger les bibliothèques nécessaires
library(ggplot2)
library(dplyr)

# Importer les données (supposées dans le répertoire de travail)
wid_data = read.csv2(file.choose(), sep = ";", stringsAsFactors = FALSE)

# Afficher les premières lignes et la structure
head(wid_data)
str(wid_data)
```

	country <chr>	variable <chr>	percentile <chr>	year <int>	value <chr>	age <int>	pop <chr>
1	IT	ehfcari999	p0p100	1990	246.339205472974	999	i
2	IT	ehfcari999	p0p100	1991	245.052525917351	999	i
3	IT	ehfcari999	p0p100	1992	279.899071393926	999	i
4	IT	ehfcari999	p0p100	1993	253.949683789973	999	i
5	IT	ehfcari999	p0p100	1994	245.476185632183	999	i
6	IT	ehfcari999	p0p100	1995	252.827726290042	999	i

6 rows

```
'data.frame':   304501 obs. of  7 variables:
 $ country   : chr  "IT" "IT" "IT" "IT" ...
 $ variable  : chr  "ehfcari999" "ehfcari999" "ehfcari999" "ehfcari999" ...
 $ percentile: chr  "p0p100" "p0p100" "p0p100" "p0p100" ...
 $ year      : int  1990 1991 1992 1993 1994 1995 1996 1997 1998 1999 ...
 $ value     : chr  "246.339205472974" "245.052525917351" "279.899071393926" "253.949683789973"
...
 $ age       : int  999 999 999 999 999 999 999 999 999 999 ...
 $ pop       : chr  "i" "i" "i" "i" ...
```

Une fois le fichier chargé, on a affiché les six premières lignes du tableau avec head() et inspecté sa structure avec str() pour identifier les variables disponibles. Les colonnes principales comprennent notamment le code du pays (country), la variable économique (variable), les centiles de population (percentile), l'année (year), la valeur mesurée (value), ainsi que des informations sur l'âge (age) et la population (pop). Cette étape nous a permis de prendre connaissance du contenu et du format des données avant de poursuivre leur filtrage et leur analyse.

---

2. Choisir une variable

Identifions les variables pertinentes, nous cherchons exactement : tptincj992 (seuil de revenu par individu adulte), aptincj992 (moyenne de revenu) et bptincj992 (coefficient β).

Si elles ne sont pas disponibles, nous cherchons des variantes (ex: tptinci992 ou tptinct992).

```{r}
# Lister les variables disponibles
variables = unique(wid_data$variable)
print(length(variables))

# Filtrer les variables de revenu pour les adultes (992) et par individu (j/i/t)
revenu_vars = variables[grepl("(tptinc|aptinc|bptinc).*992", variables)]
print(revenu_vars)
```

```
[1] 1417
[1] "aptincj992" "bptincj992" "tptincj992"
```

La variable tptincj992 est disponible.

---

3. Extraire la variable

Le fichier WID_DATA_xx choisi fait plusieurs centaines de milliers de ligne, ce qui est trop gros. Il faut en faire une copie de sauvegarde en cas d'erreur, et extraire de la copie de travail uniquement la variable qui nous intéresse, pour l'année qui nous intéresse, ce qui devrait faire environ 200 valeurs.

Extraction des années disponibles

Code R

```{r}
# Filtrer les données pour tptincj992
revenu_data = wid_data %>%
  filter(variable == "tptincj992")

# Vérifier les années disponibles
unique(revenu_data$year)
```

```
 [1] 1820 1850 1880 1900 1910 1920 1930 1940 1950 1960 1970 1980 1981 1982
1983 1984 1985 1986 1987 1988 1989 1990 1991 1992 1993 1994 1995 1996
[29] 1997 1998 1999 2000 2001 2002 2003 2004 2005 2006 2007 2008 2009 2010
2011 2012 2013 2014 2015 2016 2017 2018 2019 2020 2021 2022 2023
```

Choix de l'année qui nous intéresse

Pour notre étude, on a choisi l'année 2020 car l'Italie a été marqué par une profonde crise économique dû au COVID-19, il a été le premier pays à être toucher par cette tragédie en Europe et à avoir instauré des mesures sanitaire stricte appuyé par un confinement national en mars 2020. Chose qui a ensuite fermer le commerce, industries et transports externes. Par conséquent leur PIB a chuté de 8,9% l'un des pires recessions en Europe, mais aussi le secteur du tourisme qui a chuté de plus de 60% avec une augmentation du taux de chômage.
Et même si l'État a après mis en place un programme de relance et de soutiens aux entreprises et que le pays a reçu plus de 200 milliards d'euros du plan de relance européen, l'Italie a subi beaucoup de perte économique et démographiques impactant la vie de la population. A partir de la loi de Pareto nous allons voir si cette crise a eu impact significatif sur les 5% des plus riches en Italie (percentile > 95%).

Code R

```{r}
data_filtered = wid_data %>%
  filter(variable == "tptincj992", year == 2020)

# Vérifier le résultat
nrow(data_filtered)
```

```
[1] 387
```

Le fichier data_filtered contient 387 données de l'année 2020.

```{r}
head(data_filtered)
```

	country <chr>	variable <chr>	percentile <chr>	year <int>	value <chr>	age <int>	pop <chr>
1	IT	tptincj992	p0p1	2020	0	992	j
2	IT	tptincj992	p0p10	2020	2.7	992	j
3	IT	tptincj992	p0p100	2020	0	992	j
4	IT	tptincj992	p0p11	2020	5.800000000000001	992	j
5	IT	tptincj992	p0p12	2020	11.1	992	j
6	IT	tptincj992	p0p13	2020	19.4	992	j

6 rows

La fonction head() en langage R est utilisée pour afficher les six premières parties d'un tableau.

---

4. Tracer la courbe N(R)

Il faut extraire les percentiles au-dessus de 95%, ou même de 99% (il devrait y avoir 30 valeurs). Déterminer le revenu correspondant, et le pourcentage de population correspondant.
Par exemple, le percentile 99,3-100 correspond à 0,7% de la population, soit une proportion 0,007.
Calculer le logarithme du revenu et du pourcentage de la population ; tracer le courbe en nuage de point, et calculer sa pente en prenant deux points, si possible un peu éloignés, sur cette courbe ; il est bon de prendre plusieurs couples de points : si les pentes sont très différentes, le modèle de Pareto ne s'applique pas bien.

Extraction des données

On commence par filtrer les données pour ne garder que les percentiles correspondant aux hauts revenus, généralement à partir du 95e percentile. On utilise une expression régulière pour identifier spécifiquement les tranches de revenus supérieures comme p95p100, p96p100 jusqu'à p99p100. Ces tranches représentent respectivement les 5%, 4% jusqu'au 1% les plus riches de la population. L'objectif est de se concentrer sur la queue de distribution des revenus où la loi de Pareto s'applique traditionnellement.

Ensuite, on calcule deux éléments clés pour chaque percentile retenu. D'abord le revenu seuil R, qui correspond au montant minimum pour appartenir à cette tranche de revenus. Puis la proportion de la population N couverte par chaque tranche, calculée simplement en soustrayant la borne inférieure à 100. Par exemple, pour p95p100, N vaut (100-95)/100 = 0.05, soit 5% de la population.
Comme la loi de Pareto met une relation linéaire entre log(N) et log(R), ces valeurs sont ensuite transformées en logarithmes.

Une étape de nettoyage supprime les éventuelles valeurs manquantes ou infinies qui pourraient fausser l'analyse. Les données sont ensuite triées par ordre croissant des percentiles pour faciliter leur interprétation et leur visualisation. On affiche enfin un tableau récapitulatif montrant pour chaque tranche de revenus le percentile concerné, le revenu seuil, la proportion de population et leurs logarithmes respectifs.

Cette préparation des données permet d'estimer le coefficient alpha de Pareto par régression linéaire simple. La pente de la droite obtenue en traçant log(N) en fonction de log(R) donne une estimation de -alpha. Ce coefficient alpha est fondamental car il quantifie le degré d'inégalité dans la distribution des hauts revenus - plus alpha est élevé, plus les hauts revenus sont concentrés parmi un petit nombre

d'individus. Le coefficient beta dérivé de alpha (beta = alpha/(alpha-1)) trouve des applications importantes en économie, notamment dans les calculs de taxation optimale des hauts revenus.

Code R

```{r}
library(tidyverse)
library(stringr)

# 1. Filtrer les percentiles ≥ 95% et calculer N et R
pareto_data = data_filtered %>%
  # Garder uniquement les percentiles de la forme pXXp100 où XX >= 95
  filter(
    grepl("^p(9[5-9]|100)p100$", percentile)  # Prend p95p100, p96p100, ..., p99.9p100
  ) %>%
  # Convertir 'value' en revenu (R) et calculer N
  mutate(
    R = as.numeric(value),  # Revenu seuil
    # Extraire la borne inférieure du percentile (ex: "p95p100" → 95)
    lower = as.numeric(str_extract(percentile, "(?<=^p)\\d+")),
    N = (100 - lower) / 100,  # Proportion de population (ex: 0.05 pour p95p100)
    log_N = log(N),
    log_R = log(R)
  ) %>%
  # Supprimer les NA/Inf (sécurité)
  drop_na() %>%
  # Trier par percentile
  arrange(lower)

# 2. Afficher les données
print(pareto_data %>% select(percentile, R, N, log_N, log_R))
```

percentile <chr>	R <dbl>	N <dbl>	log_N <dbl>	log_R <dbl>
p95p100	77638.0	0.05	-2.995732	11.25981
p96p100	86668.0	0.04	-3.218876	11.36984
p97p100	99813.6	0.03	-3.506558	11.51106
p98p100	124358.7	0.02	-3.912023	11.73093
p99p100	156871.3	0.01	-4.605170	11.96318

Le tableau généré par le code nous montre une analyse de l'augmentation des revenus en Italie pour l'année 2020, qui illustre une distribution caractéristique de la loi de Pareto. Cette loi décrit comment une petite fraction de la population détient une part disproportionnée des revenus ou des richesses. L'analyse montre que les 5% des plis riches (p95p100) ont un revenu minimum de 77 638 euros alors que le seuil augmente à 156 871 euros du 1% supérieur (p99p100). Ainsi, les riches deviennent de plus en plus riches, et de plus en plus vite, par rapport au reste de la population.

Le fait d'avoir transformer en logarithme (log_N et log_R) révèle une relation quasi linéaire entre le rang des percentiles et les revenus, ce qui confirme que cette distribution suit approximativement une loi de puissance. Donc plus on se concentre sur les percentiles élevés, plus les revenus grimpent de manière disproportionnée. Et comme l'Italie présente une concentration marquée des richesses dans la distribution, ce qui nous montre que notre cette analyse est tout à fait cohérente par apports aux études économiques sur les inégalités. Les résultats suggèrent que les politiques fiscales ou sociales ciblant les hauts revenus pourraient avoir un impact significatif sur la réduction des inégalités.

Courbe de Loi Pareto

```
# 3. Tracer la courbe log(N) vs log(R)
ggplot(pareto_data, aes(x = log_R, y = log_N)) +
  geom_point(color = "red", size = 3) +
  geom_smooth(method = "lm", se = FALSE, color = "blue") +  # Régression linéaire
  labs(
    title = "Loi de Pareto : log(N) en fonction de log(R)",
    x = "log(Revenu seuil R)",
    y = "log(Proportion de population N)"
  ) +
  theme_minimal()
```

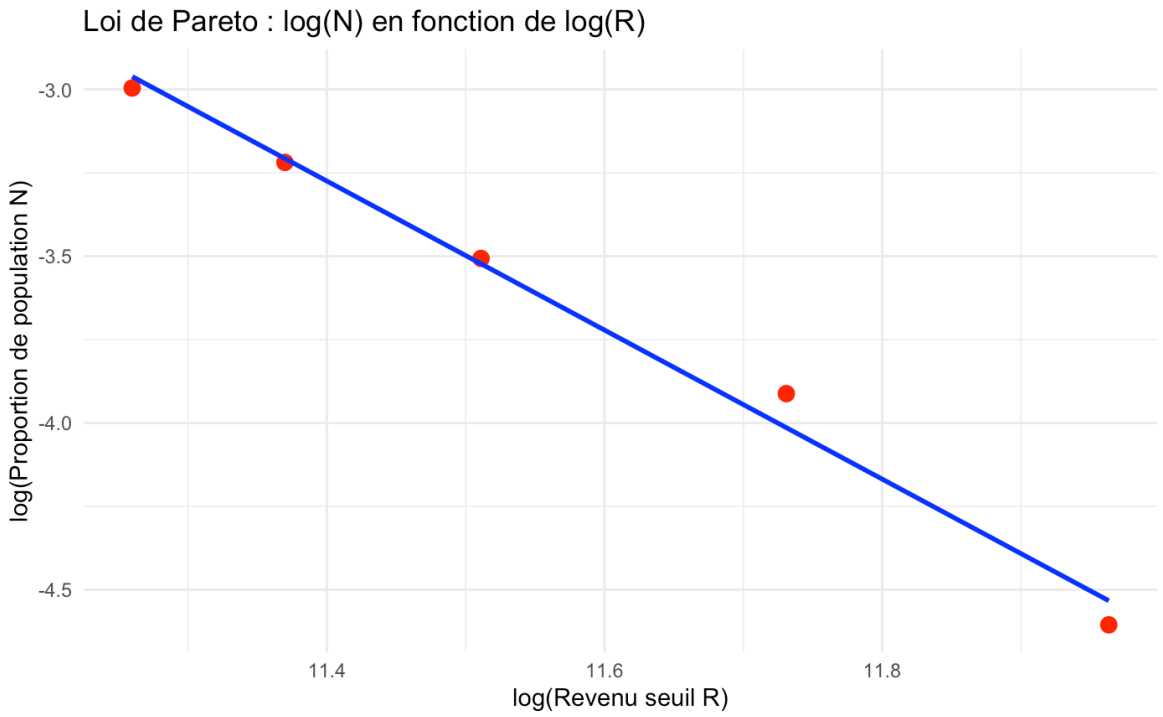

Non-linéarité aux extrêmes **:** bien que la loi de Pareto prédise une relation linéaire entre log(N) et log(R) dans une certaine plage, les très hauts percentiles (comme p98-p100) peuvent s'en écarter. Ce qui montre une accélération plus forte des revenus dans l'extrême queue de la distribution, typique des "super-riches". En Italie, les 2 % les plus aisés (p98p100) pourraient inclure des catégories aux revenus disproportionnés créant une rupture de pente.

---

5. Calculer α et β

Régression linéaire

On va effectuer une régression linéaire pour estimer le coefficient α de la loi de Pareto, puis calculer le coefficient β à partir de α :

lm(log_N ~ log_R, data = pareto_data)
Une régression linéaire est ajustée où log_N (logarithme de la proportion de la population) est expliqué par log_R (logarithme du revenu).

Dans la loi de Pareto, on s'attend à une relation linéaire de la forme :

$$\log(N) = \log(C) - \alpha (\log(R))$$

Où **α** est l'exposant de Pareto, mesurant l'inégalité.

alpha = -coef(model)[2]
La pente de la régression (log_R) est négative (car plus le revenu est élevé, plus la proportion de la population est faible). On prend donc son opposé pour obtenir α (qui doit être positif).

beta = alpha/(alpha-1)
β est un autre paramètre de Pareto, lié à α, qui décrit comment la moyenne des revenus au-dessus d'un seuil évolue. Si α > 1, la distribution a une variance finie (condition nécessaire pour des analyses économiques robustes).

Code R

```
# 4. Calculer le coefficient α de Pareto
model = lm(log_N ~ log_R, data = pareto_data)
alpha = -coef(model)[2]  # Pente négative (N ~ R^(-α))
print(paste("Coefficient de Pareto (α) =", round(alpha, 2)))
beta = alpha/(alpha-1)
print(paste("Coefficient β =", round(beta, 2)))
```

```
[1] "Coefficient de Pareto (α) = 2.23"
[1] "Coefficient β = 1.81"
```

α = 2.23 indique une inégalité modérée à forte, plus α est élevé, plus la queue de distribution est mince (moins d'extrêmes riches). L'Italie (2020) semble donc avoir des inégalités légèrement plus marquées.

β = 1.81 signifie que pour les hauts revenus (au-delà d'un seuil), un accroissement de 1% du seuil s'accompagne d'une augmentation de 1.81 % de la moyenne des revenus au-dessus de ce seuil. Cela confirme que les très hauts revenus croissent plus vite que le seuil lui-même, un signe classique de concentration des richesses.

Le Modèle de Pareto est-il Justifié ?

Le modèle de Pareto semble globalement justifié pour ces données, car la relation log-linéaire est cohérente et α est supérieur à 1, une condition nécessaire pour une distribution réaliste. Cependant, des écarts peuvent exister pour les percentiles les plus élevés (comme p98p100), où d'autres facteurs comme les revenus du capital ou l'optimisation fiscale pourraient perturber la tendance. Ces résultats permettent d'évaluer les inégalités et pourraient guider des politiques fiscales ciblées. Par exemple, avec α = 2.23, on peut estimer que les 0.1% les plus riches gagnent environ 467 000 €, ce qui illustre l'utilité pratique de ce modèle pour analyser les extrêmes de la distribution des revenus

---

6. (Facultatif)

Recommencer pour quelques autres années (la deuxième fois, ça va beaucoup plus vite)
Est-ce que le coefficient β varie ? Peut-on relier cette variation à des évènements historiques ?

On choisit l'année 1940

percentile <chr>	R <dbl>	N <dbl>	log_N <dbl>	log_R <dbl>
p95p100	11340.9	0.05	-2.995732	9.336171
p96p100	12106.2	0.04	-3.218876	9.401473
p97p100	14819.1	0.03	-3.506558	9.603672
p98p100	20142.8	0.02	-3.912023	9.910602
p99p100	25192.1	0.01	-4.605170	10.134286

5 rows

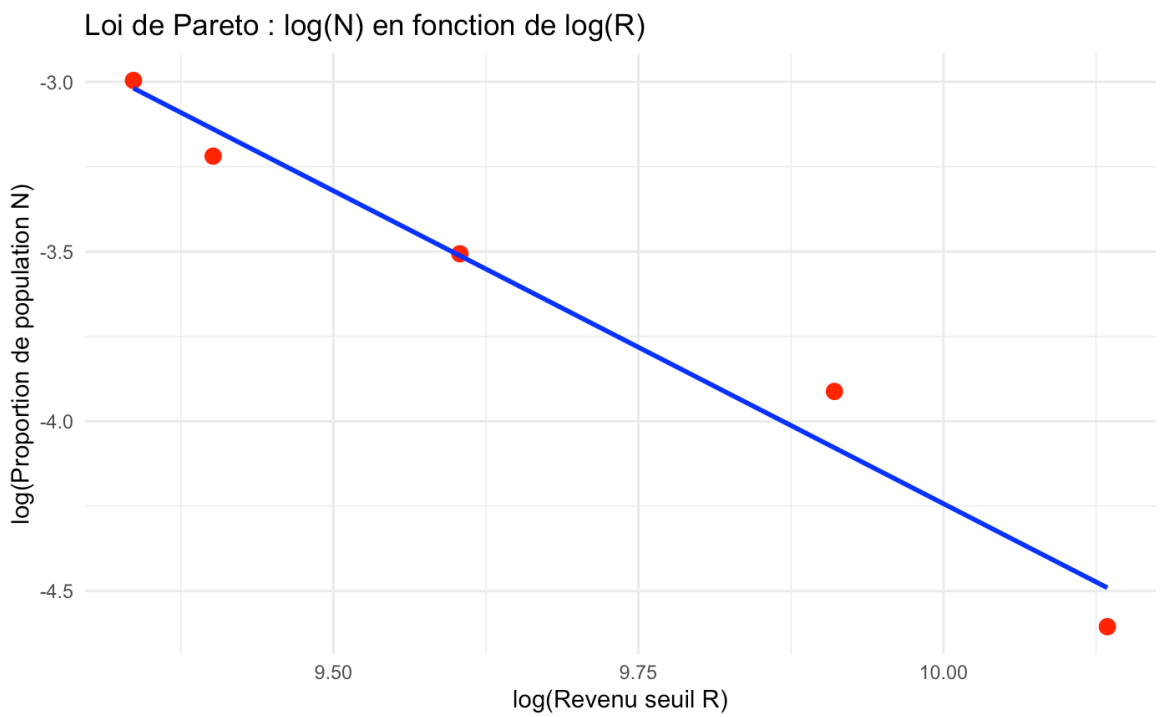


```
[1] "Coefficient de Pareto (α) = 1.84"
[1] "Coefficient β = 2.18"
```

Le coefficient β varie effectivement entre les deux périodes étudiées, passant de 2.18 en 1940 à 1.81 en 2020. Cette évolution révèle une transformation profonde de la structure des inégalités de revenus en Italie au cours du XXe siècle. La valeur plus élevée de β en 1940 indique que les très hauts revenus augmentaient de manière particulièrement rapide par rapport aux seuils des percentiles supérieurs, reflétant une concentration extrême des richesses caractéristique d'une société prémoderne marquée par des élites restreintes et des institutions peu redistributives.

Le contexte historique de 1940 explique en grande partie cette configuration. L'Italie fasciste de Mussolini présentait une économie fortement contrôlée où les privilèges des élites industrielles et politiques se renforçaient, tandis que la majorité de la population subissait les contraintes d'une économie de guerre. Les mécanismes de redistribution étaient quasi-inexistants, et la structure productive, encore largement agricole et industrielle, favorisait l'accumulation de richesses dans quelques mains. Cette période trouble précédant l'entrée dans la Seconde Guerre mondiale créait des conditions propices à l'exacerbation des inégalités.

CONCLUSION

En 2020, l'Italie n'est plus la même qu'il y a un siècle. Grâce à la mise en place de l'État-providence, à des impôts plus justes et à une économie de plus en plus tournée vers les services, les écarts de revenus les plus extrêmes se sont réduits. Cela ne veut pas dire que les inégalités ont disparu, mais elles sont moins violentes qu'avant, quand l'économie était surtout basée sur l'industrie lourde et qu'une petite partie de la population concentrait l'essentiel des richesses.

Les grandes crises, comme celle de 2008 ou la pandémie de COVID-19, ont cependant rappelé que les progrès restent fragiles : à chaque choc, les inégalités peuvent repartir à la hausse, et de nombreuses familles ont basculé dans la pauvreté, surtout dans le Sud du pays. Les Italiens du Sud gagnent encore nettement moins que ceux du Nord, et les familles nombreuses ou ouvrières sont particulièrement vulnérables.

L'évolution de l'indicateur β, qui mesure la répartition des revenus, n'est donc pas due au hasard : elle reflète toutes ces transformations politiques, économiques et sociales. Les lois, les choix économiques et les crises historiques laissent des traces durables sur la façon dont les richesses sont partagées. Si on regardait de plus près d'autres moments clés de l'histoire italienne, on pourrait repérer plus précisément quand et comment les inégalités ont changé.

Cette étude montre l'intérêt d'outils comme la loi de Pareto pour comprendre l'évolution des inégalités sur le long terme, et rappelle que derrière les chiffres, il y a des histoires de familles, de régions, de politiques publiques et de crises qui façonnent la vie des Italiens. Pour aller plus loin, il serait utile de comparer d'autres périodes ou d'analyser l'effet de politiques précises, car on ne peut pas comprendre les inégalités sans tenir compte du contexte historique et institutionnel du pays

BIBLIOGRAPHIE

Gabaix, X. (2009). "Power Laws in Economics and Finance." *Annual Review of Economics*, 1(1), 255-294.

Fondements théoriques et empiriques des lois de puissance en économie, dont la distribution de Pareto.

Clementi, F., & Gallegati, M. (2005). "Pareto's Law of Income Distribution: Evidence for Germany, the United Kingdom, and the United States." *Econophysics of Wealth Distributions*, 3-14.

Étude empirique comparée des distributions de revenus dans différents pays.

Rossi, N., Toniolo, G., & Vecchi, G. (2001). "Is the Kuznets Curve Still Alive? Evidence from Italian Household Budgets, 1881–1961." *The Journal of Economic History*, 61(4), 904-925.

Analyse des inégalités en Italie sur une longue période, incluant l'ère fasciste.

Brandolini, A., & Vecchi, G. (2011). "The Well-Being of Italians: A Comparative Historical Approach." *Bank of Italy Economic History Working Paper*, 19.

Évolution du niveau de vie et des disparités économiques en Italie au XXe siècle.

Newman, M. E. J. (2005). "Power Laws, Pareto Distributions and Zipf's Law." *Contemporary Physics*, 46(5), 323-351.

Guide méthodologique pour l'analyse des distributions de Pareto.

https://fr.wikipedia.org/wiki/Loi_de_Pareto